

Probabilidade e Distribuição Normal aplicadas à Inteligência Artificial

Previsão de atrasos em entregas: estudo aplicado à Logística com dados simulados em Python

INTEGRANTES

Giovanni Henrique Pereira Hessel (RM 570574)

Suellen Pereira da Silva (RM 573862)

Arthur Zeferino (RM 570858)

Israel Carneiro de Toledo (RM 573854)

1 Introdução e Justificativa

Por que probabilidade é a linguagem da Inteligência Artificial

Trânsito, clima e distância mudam o tempo de cada entrega, então toda previsão de prazo carrega incerteza. Um modelo preditivo não responde com certezas, e sim com probabilidades. Entender Probabilidade e Distribuição Normal é, portanto, condição para construir e interpretar esse tipo de modelo.

1 Contexto: Transportadora urbana com SLA de 60 minutos por entrega.

2 Problema: Quais fatores elevam o risco de atraso e qual a chance de estourar o prazo?

3 Solução: Modelo probabilístico (Naive Bayes Gaussiano) escrito do zero em Python.

4 Dados: Base simulada com números pseudoaleatórios (seed = 42), o que torna o estudo reprodutível.

O QUE VAMOS RESPONDER

1. Qual a probabilidade de uma entrega atrasar?
2. Quanto a chuva aumenta esse risco?
3. O tempo de entrega segue uma Normal?
4. A IA consegue prever o atraso antes de ele acontecer?
5. Que decisão gerencial reduz mais o risco?

2 Probabilidade: conceitos e fórmulas

Tema 1: a base matemática do raciocínio sob incerteza

Probabilidade clássica

$$P(A) = \text{casos favoráveis} / \text{casos possíveis}$$

Frequência relativa do evento na base observada.

Probabilidade condicional

$$P(A|B) = P(A \cap B) / P(B)$$

Atualiza a chance de A quando já se sabe que B ocorreu.

Teorema de Bayes

$$P(B|A) = P(A|B) \cdot P(B) / P(A)$$

Inverte a condicional e sustenta os classificadores probabilísticos.

AXIOMAS DE KOLMOGOROV

$$0 \leq P(A) \leq 1$$

$$P(\text{espaço amostral}) = 1$$

$$A \text{ e } B \text{ disjuntos} \Rightarrow P(A \cup B) = P(A) + P(B)$$

Onde isso aparece na IA

Classificadores como Naïve Bayes e regressão logística

- Saída de redes neurais pela função softmax
- Filtros de spam e sistemas de recomendação
- Cálculo de risco e precificação de seguros

3 A base de dados: números pseudoaleatórios

Simulação controlada de 1.000 entregas urbanas em Python

O computador não gera acaso verdadeiro. Um algoritmo determinístico parte de uma semente (seed) e produz uma sequência com propriedades estatísticas de aleatoriedade. Como a semente está fixa, qualquer execução devolve os mesmos números.

```
rng = np.random.default_rng(42) # semente fixa

distancia = np.clip(rng.normal(12, 4, n), 1, None)
chuva      = rng.binomial(1, 0.30, n) # Bernoulli
pico       = rng.binomial(1, 0.40, n) # Bernoulli

tempo = (6 + 3.0*distancia + 12*chuva + 9*pico
         + rng.normal(0, 7, n)) # ruído Normal

df['atraso'] = (df['tempo_min'] > 60).astype(int)
```

Cada variável tem uma distribuição por trás

Distância ~ Normal(12; 4), Chuva ~ Bernoulli(0,30), Pico ~ Bernoulli(0,40), Erro ~ Normal(0; 7)

1.000 **42** **5**
entregas simuladas semente (seed) variáveis

Amostra da base gerada (df.head)


distância	chuva	pico	tempo	atraso
13,22 km	0	1	49,9	0
15,76 km	0	1	69,5	1
4,20 km	0	1	27,2	0
12,51 km	0	1	48,4	0

A coluna alvo segue uma regra simples: atraso = 1 quando o tempo simulado ultrapassa o SLA de 60 minutos.

4

Probabilidade condicional na prática

Executando o código: como cada fator muda o risco de atraso



LEITURA DOS RESULTADOS

P(atraso) **22,5%**

P(atraso | sem chuva) **14,3%**

P(atraso | chuva) **41,0%**

P(atraso | pico) **36,1%**

P(atraso | chuva e pico) 64,7%

Risco relativo da chuva

2,87x

Com chuva, a chance de estourar o prazo quase triplica.

```
P(atraso | chuva) = df.loc[df['chuva']==1, 'atraso'].mean()
```

5

Teorema de Bayes: invertendo a pergunta

De “está chovendo, qual a chance de atrasar?” para “atrasou, o que provavelmente aconteceu?”

$$P(\text{chuva} \mid \text{atraso}) = P(\text{atraso} \mid \text{chuva}) \cdot P(\text{chuva}) / P(\text{atraso}) = 0,410 \cdot 0,307 / 0,225 = 0,560$$

Verossimilhança

$$P(\text{atraso} \mid \text{chuva}) = 0,410$$

O que a base mostra sobre o efeito da chuva.

Priori

$$P(\text{chuva}) = 0,307$$

Chance de chuva antes de observar a entrega.

Evidência

$$P(\text{atraso}) = 0,225$$

Normaliza o resultado para virar probabilidade.

Posteriori

$$P(\text{chuva} \mid \text{atraso}) = 0,560$$


56% das entregas atrasadas ocorreram sob chuva.

Validação no código: o valor calculado pela fórmula (0,560) coincide com a frequência observada na base, `df.loc[df['atraso']==1, 'chuva'].mean() = 0,560`.

6

Distribuição Normal: modelando o tempo

Tema 2: a curva que descreve grandezas contínuas somadas



Com média e desvio conhecidos, a curva responde qualquer pergunta de prazo, inclusive sobre valores que a base não observou.

$$f(x) = \frac{1}{(\sigma\sqrt{2\pi})} \cdot e^{-(x-\mu)^2/2\sigma^2}$$

48,9

média μ (min)

15,4

desvio σ (min)

Padronização (escore z)

$$z = \frac{60 - 48,94}{15,42} = 0,717$$

$$P(T > 60) = 1 - \Phi(0,717) = 23,7\%$$


Empírico na base = 22,5%

Percentil 95: prometer 75 min cumpriria o prazo em 95% das entregas.

7 Por que a Normal aparece tanto?

Teste de normalidade, regra empírica e Teorema Central do Limite

Teorema Central do Limite: a media amostral tende a Normal



Mesmo partindo de uma população fortemente assimétrica (exponencial), a distribuição das médias amostrais converge para a Normal conforme n cresce. Essa é a razão de a curva aparecer em tantos métodos estatísticos.

Regra empírica 68-95-99,7

Intervalo	Teórico	Observado
$\mu \pm 1\sigma$	68,27%	67,00%
$\mu \pm 2\sigma$	95,45%	95,90%
$\mu \pm 3\sigma$	99,73%	99,80%

Shapiro-Wilk

$W = 0,995$ | $p = 0,093$

Como $p > 0,05$, não rejeitamos H_0 : os dados são compatíveis com a Normal.

ONDE A NORMAL É USADA

- Inicialização de pesos de redes neurais (Xavier, He)
- Padronização de variáveis (z-score) antes do treino
- Verossimilhança gaussiana no Naive Bayes
- Detecção de anomalias acima de 3σ
- Ruído gaussiano em modelos de difusão
- Intervalos de confiança das métricas do modelo

8 Classificador Naive Bayes Gaussiano

Onde os dois temas se encontram: Bayes decide e a Normal calcula

Para cada classe, o modelo estima a probabilidade a priori e uma curva Normal por variável. Diante de uma nova entrega, multiplica priori e verossimilhanças e escolhe a classe de maior probabilidade a posteriori.

$$P(\text{classe} \mid \mathbf{x}) \propto P(\text{classe}) \cdot \prod P(x_i \mid \text{classe})$$

- Treino com 70% da base: calcula $P(\text{classe})$, μ e σ de cada variável.
- O termo “naive” vem da suposição de independência entre as variáveis.
- A verossimilhança contínua usa a densidade da Normal na distância.
- A saída é uma probabilidade, e não apenas um rótulo.



```
def densidade_normal(x, mu, sigma):  
    return (1/(sigma*np.sqrt(2*np.pi))) * \  
           np.exp(-((x-mu)**2)/(2*sigma**2))  
  
def prever(X):  
    posterioris = []  
    for classe in [0, 1]:  
        p = parametros[classe]  
        veros = densidade_normal(  
            X, p['media'], p['desvio'])  
        posterioris.append(p['priori'] * veros)  
    post = np.vstack(posterioris)  
    post = post / post.sum(axis=0) # normaliza  
    return post.argmax(axis=0), post[1]
```

Nenhuma biblioteca de machine learning foi usada. O modelo usa apenas probabilidade e a fórmula da Normal.

9

Resultados e simulação de cenários

Desempenho no conjunto de teste (300 entregas nunca vistas)



87,3%

Acurácia

89,1%

Precisão

55,4%

Recall

0,683

F1-score

Precisão alta e recall moderado. Quando o modelo aponta atraso, quase sempre acerta, mas deixa passar parte dos atrasos limítrofes.

PREVISÃO PARA NOVAS ENTREGAS


5 km, tempo bom	0,0%
12 km, com chuva	20,6%
18 km, horário de pico	69,9%
20 km, chuva e pico	97,7%

Uso na operação

Com o risco calculado pedido a pedido, a operação consegue reforçar a frota, reroteirizar ou avisar o cliente antes que o prazo estoure.

10 Simulação de Monte Carlo

20.000 sorteios por cenário para comparar decisões



```
amostras = rng.normal(mu, sigma, 20000)
risco = (amostras > 60).mean()
```

REDUÇÃO DO RISCO

23,7% → 6,8%

Queda de 17 pontos percentuais combinando roteirização automática e padronização da frota, o que representa cerca de 17 mil entregas atrasadas a menos a cada 100 mil.

Leitura dos cenários

- Neste caso, reduzir a média (μ) pesa mais do que reduzir o desvio (σ).
- As duas ações combinadas derrubam o risco a menos de um terço.
- Simular a decisão antes de aplicá-la evita testar hipóteses na operação real.

Conclusão

Análise dos resultados e benefícios da solução

1 A média escondia o risco real

A taxa geral de 22,5% de atrasos convivía com cenários de 64,7%. Foram a probabilidade condicional e o Teorema de Bayes que mostraram onde o risco se concentra.

2 A Normal descreveu bem o tempo

Com $\mu = 48,9$ e $\sigma = 15,4$ min, a curva estimou 23,7% de estouro de SLA, contra 22,5% observados, e apontou 75 min como prazo capaz de cobrir 95% das entregas.

3 Do conceito ao modelo preditivo

Um Naive Bayes Gaussiano escrito do zero, usando apenas Bayes e a densidade normal, atingiu 87,3% de acurácia e 89,1% de precisão em dados nunca vistos.

4 Ganho possível para a operação

A simulação de Monte Carlo apontou queda do risco de 23,7% para 6,8%, com reflexo em multas de SLA, retrabalho logístico e satisfação do cliente.

Como continuidade, o mesmo modelo poderia ser treinado com dados reais de telemetria e comparado com regressão logística e gradient boosting.

11 Bibliografia

Referências segundo as normas da ABNT (NBR 6023)

BUSSAB, Wilson de O.; MORETTIN, Pedro A. Estatística básica. 9. ed. São Paulo: Saraiva, 2017.

MONTGOMERY, Douglas C.; RUNGER, George C. Estatística aplicada e probabilidade para engenheiros. 7. ed. Rio de Janeiro: LTC, 2021.

FÁVERO, Luiz Paulo; BELFIORE, Patrícia. Manual de análise de dados: estatística e modelagem multivariada. Rio de Janeiro: LTC, 2017.

JAMES, Gareth et al. An introduction to statistical learning: with applications in Python. Cham: Springer, 2023.

GÉRON, Aurélien. Mãos à obra: aprendizado de máquina com Scikit-Learn, Keras & TensorFlow. 2. ed. Rio de Janeiro: Alta Books, 2021.

MCKINNEY, Wes. Python para análise de dados: tratamento de dados com Pandas, NumPy e Jupyter. 3. ed. São Paulo: Novatec, 2023.

NUMPY DEVELOPERS. NumPy documentation: random sampling (numpy.random). Disponível em: <https://numpy.org/doc/stable/reference/random/index.html>. Acesso em: 10 set. 2026.

SCIPY COMMUNITY. SciPy documentation: statistical functions (scipy.stats). Disponível em: <https://docs.scipy.org/doc/scipy/reference/stats.html>. Acesso em: 10 set. 2026.

ANTHROPIC. Claude: modelo de linguagem de grande porte. Versão Opus 5. San Francisco: Anthropic, 2026. Disponível em: <https://claude.ai>. Acesso em: 10 set. 2026. Utilizado como apoio na estruturação da apresentação e na revisão do código.

Código-fonte completo no arquivo `codigo_cp4.py`, executado em Python 3.11 com NumPy, pandas, SciPy e Matplotlib.