

Probabilidade e Distribuição Normal aplicadas à Inteligência Artificial

Previsão de atrasos em entregas: estudo aplicado à Logística com dados simulados em Python

INTEGRANTES

Giovanni Henrique Pereira Hessel (RM 570574)

Suellen Pereira da Silva (RM 573862)

Arthur Zeferino (RM 570858)

Israel Carneiro de Toledo (RM 573854)

2º Semestre, Tecnólogo em Inteligência Artificial | Professor: Me. Eng. Rodolfo Magliari de Paiva

1 Introdução e Justificativa

Qual problema escolhemos e por que ele precisa de probabilidade

Uma transportadora promete entregar em até 60 minutos. Só que trânsito, chuva e distância mudam esse tempo, então ninguém tem certeza se vai dar. Quando a certeza não existe, a saída é calcular a chance de acontecer. É isso que os dois temas fazem, e é assim que um programa de computador consegue prever.

1 Contexto: Transportadora urbana com SLA de 60 minutos por entrega.

2 Problema: Quais fatores elevam o risco de atraso e qual a chance de estourar o prazo?

3 Solução: Um programa em Python que calcula a chance de atraso de cada entrega.

4 Dados: Mil entregas criadas pelo próprio código, sempre iguais por causa da semente fixa.

O QUE VAMOS RESPONDER

1. Qual a probabilidade de uma entrega atrasar?
2. Quanto a chuva aumenta esse risco?
3. O tempo de entrega segue uma Normal?
4. Dá para prever o atraso antes de ele acontecer?
5. Qual mudança na operação reduz mais o risco?

2 Probabilidade: conceitos e fórmulas

Tema 1: as três fórmulas que usamos no trabalho

Probabilidade

$$P(A) = \text{casos favoráveis} / \text{casos possíveis}$$

Quantas vezes o evento aconteceu, dividido pelo total.

Exemplo: Num dado comum, a chance de sair 6 é 1 em 6, ou seja, 16,7%.

Probabilidade condicional

$$P(A|B) = P(A \text{ e } B) / P(B)$$

A chance de algo acontecer quando já sabemos que outra coisa aconteceu.

Exemplo: Se alguém já disse que saiu número par, a chance de ser 6 sobe para 1 em 3.

Teorema de Bayes

$$P(B|A) = P(A|B) \times P(B) / P(A)$$

Vira a pergunta do avesso: a partir do resultado, descobre a causa provável.

Exemplo: O médico vê a febre e calcula qual doença é a causa mais provável.

REGRAS BÁSICAS

Toda chance fica entre 0 e 1 (0% e 100%)

A soma de todas as possibilidades dá 1

Se A e B não acontecem juntos, somam-se as chances

Onde isso é usado

- Aplicativo que avisa se vai chover hoje
- Filtro que separa e-mail de spam
- Banco que avalia risco de um empréstimo
- Netflix e YouTube sugerindo o próximo vídeo

3

A base de dados: números pseudoaleatórios

Mil entregas criadas pelo próprio programa

O computador não sorteia de verdade. Ele segue uma conta que parte de um número inicial, a semente, e devolve valores que parecem sorteados. Como a semente está fixa em 42, rodar o código hoje ou amanhã dá exatamente o mesmo resultado.

```
rng = np.random.default_rng(42) # semente fixa

distancia = np.clip(rng.normal(12, 4, n), 1, None)
chuva      = rng.binomial(1, 0.30, n) # Bernoulli
pico       = rng.binomial(1, 0.40, n) # Bernoulli

tempo = (6 + 3.0*distancia + 12*chuva + 9*pico
         + rng.normal(0, 7, n)) # ruído Normal

df['atraso'] = (df['tempo_min'] > 60).astype(int)
```

Parece sorteio, mas é repetível

É como um baralho embaralhado sempre da mesma forma: o resultado parece sorteado, mas qualquer pessoa consegue repetir o mesmo embaralhamento e conferir nossas contas.

1.000

entregas simuladas

42

semente (seed)

5

variáveis

Amostra da base gerada (df.head)


distância	chuva	pico	tempo	atraso
13,22 km	0	1	49,9	0
15,76 km	0	1	69,5	1
4,20 km	0	1	27,2	0
12,51 km	0	1	48,4	0

A última coluna é o que queremos prever: vale 1 quando o tempo passa de 60 minutos.

4

Probabilidade condicional na prática

Rodando o código: o risco muda muito de um cenário para outro



LEITURA DOS RESULTADOS

P(atraso) **22,5%**

P(atraso | sem chuva) **14,3%**

P(atraso | chuva) **41,0%**

P(atraso | pico) **36,1%**

P(atraso | chuva e pico) 64,7%

Risco relativo da chuva

2,87×

Com chuva, a chance de perder o prazo quase triplica.

```
P(atraso | chuva) = df.loc[df['chuva']==1, 'atraso'].mean()
```

5 Teorema de Bayes na prática

De “está chovendo, qual a chance de atrasar?” para “atrasou, o que provavelmente aconteceu?”

$$P(\text{chuva} \mid \text{atraso}) = \frac{P(\text{atraso} \mid \text{chuva}) \cdot P(\text{chuva})}{P(\text{atraso})} = \frac{0,410 \cdot 0,307}{0,225} = 0,560$$

O que já sabemos

$$P(\text{atraso} \mid \text{chuva}) = 0,410$$

Das entregas com chuva, 41% atrasaram.

Chance de chover

$$P(\text{chuva}) = 0,307$$

Choveu em 30,7% das entregas da base.

Chance de atrasar

$$P(\text{atraso}) = 0,225$$

22,5% de todas as entregas atrasaram.


Resposta

$$P(\text{chuva} \mid \text{atraso}) = 0,560$$

Das entregas que atrasaram, 56% foram em dia de chuva.

Conferindo no código: contamos na base quantas entregas atrasadas tiveram chuva e deu 0,560, exatamente o mesmo valor da fórmula.

Tema 2: a curva em formato de sino



A altura das pessoas e as notas de uma prova se comportam assim: a maioria fica perto da média e poucos ficam nos extremos. Com o tempo de entrega acontece o mesmo.

$$f(x) = 1/(\sigma\sqrt{2\pi}) \cdot e^{-(x-\mu)^2/2\sigma^2}$$

48,9

média μ (min)

15,4

desvio σ (min)

Chance de passar dos 60 minutos

$$z = (60 - 48,94) / 15,42 = 0,717$$
$$P(T > 60) = 1 - \Phi(0,717) = 23,7\%$$


Empírico na base = 22,5%

A curva também mostra que prometer 75 minutos daria conta de 95% das entregas.

7 Por que essa curva aparece tanto?

Conferindo se os dados realmente seguem a curva Normal

Teorema Central do Limite: a media amostral tende a Normal



No primeiro gráfico os dados são bem tortos, nada parecido com um sino. Mas quando tiramos médias de grupos de 5 e depois de 50, o desenho vai virando o sino da Normal. Por isso essa curva aparece em quase tudo.

Regra empírica 68-95-99,7

Intervalo	Teórico	Observado
$\mu \pm 1\sigma$	68,27%	67,00%
$\mu \pm 2\sigma$	95,45%	95,90%
$\mu \pm 3\sigma$	99,73%	99,80%

Shapiro-Wilk

$W = 0,995$ | $p = 0,093$

O valor de p ficou acima de 0,05, então os dados combinam com a Normal.

ONDE A CURVA NORMAL É USADA

- Ajuste inicial de redes neurais
- Deixar variáveis na mesma escala
- O modelo que usamos no próximo slide
- Encontrar valores fora do normal
- Programas que geram imagens
- Margem de erro de pesquisas e testes

O modelo que junta os dois temas

O modelo aprende como é cada grupo, entregas no prazo e entregas atrasadas: distância média, quanto chove e quanto pega horário de pico. Diante de uma entrega nova, compara com os dois grupos, escolhe o mais parecido e diz em quantos por cento confia.



$$P(\text{grupo} \mid \text{dados}) = P(\text{grupo}) \times P(\text{dados} \mid \text{grupo})$$

- Treinamos com 70% das entregas e testamos nas outras 30%.
- O nome “naive”, ingênuo, vem de tratar as colunas como independentes.
- A curva Normal entra para medir o quanto a distância combina com cada grupo.
- A resposta vem em porcentagem, não só um sim ou não.

```
def densidade_normal(x, mu, sigma):  
    return (1/(sigma*np.sqrt(2*np.pi))) * \  
           np.exp(-((x-mu)**2)/(2*sigma**2))  
  
def prever(X):  
    posterioris = []  
    for classe in [0, 1]:  
        p = parametros[classe]  
        veros = densidade_normal(  
            X, p['media'], p['desvio']).prod(axis=1)  
        posterioris.append(p['priori'] * veros)  
    post = np.vstack(posterioris)  
    post = post / post.sum(axis=0) # normaliza  
    return post.argmax(axis=0), post[1]
```

É o mesmo raciocínio de olhar uma fruta e dizer se é laranja ou limão pelo tamanho e pela cor: comparamos com o que já vimos antes de cada uma.

Testamos em 300 entregas que o modelo nunca tinha visto



87,3%

Acurácia

89,1%

Precisão

55,4%

Recall

0,683

F1-score

PREVISÃO PARA NOVAS ENTREGAS

5 km, tempo bom	0,0%
12 km, com chuva	20,6%
18 km, horário de pico	69,9%
20 km, chuva e pico	97,7%


Uso na operação

Sabendo o risco de cada pedido antes de sair, a empresa pode mandar outro veículo, mudar a rota ou avisar o cliente antes do prazo estourar.

Quando o modelo avisa que vai atrasar, ele quase sempre acerta. O ponto fraco é deixar escapar algumas entregas que atrasaram por pouco.

10 Simulação de Monte Carlo

Testando mudanças na operação antes de aplicá-las



```
amostras = rng.normal(mu, sigma, 20000)
risco = (amostras > 60).mean()
```

REDUÇÃO DO RISCO

23,7% → 6,8%

Fazendo as duas mudanças juntas, o risco cai 17 pontos. Em cada 100 mil entregas, são cerca de 17 mil atrasos a menos.

Leitura dos cenários

- Ganhar tempo médio ajudou mais do que reduzir a variação.
- As duas mudanças juntas derrubam o risco a menos de um terço.
- Simular no computador evita testar a mudança direto na rua.

Conclusão

Análise dos resultados e benefícios da solução

1 A média escondia o risco real

Olhando só o total, 22,5% das entregas atrasam. Separando por cenário, o risco chega a 64,7%. A probabilidade mostrou onde estava o problema.

2 A curva Normal descreveu o tempo

Com média de 48,9 e desvio de 15,4 minutos, a curva calculou 23,7% de risco, bem perto dos 22,5% que realmente aconteceram.

3 Da fórmula ao programa que prevê

Usando só as fórmulas dos slides, o modelo acertou 87,3% das entregas de teste, que ele nunca tinha visto antes.

4 O ganho para a empresa

Na simulação, o risco cai de 23,7% para 6,8%. Isso significa menos multa por atraso, menos retrabalho e cliente mais satisfeito.

Como próximo passo, o mesmo modelo poderia ser testado com dados reais da empresa e comparado com outros métodos.

Referências segundo as normas da ABNT (NBR 6023)

BUSSAB, Wilson de O.; MORETTIN, Pedro A. Estatística básica. 9. ed. São Paulo: Saraiva, 2017.

MONTGOMERY, Douglas C.; RUNGER, George C. Estatística aplicada e probabilidade para engenheiros. 7. ed. Rio de Janeiro: LTC, 2021.

FÁVERO, Luiz Paulo; BELFIORE, Patrícia. Manual de análise de dados: estatística e modelagem multivariada. Rio de Janeiro: LTC, 2017.

JAMES, Gareth et al. An introduction to statistical learning: with applications in Python. Cham: Springer, 2023.

GÉRON, Aurélien. Mãos à obra: aprendizado de máquina com Scikit-Learn, Keras & TensorFlow. 2. ed. Rio de Janeiro: Alta Books, 2021.

MCKINNEY, Wes. Python para análise de dados: tratamento de dados com Pandas, NumPy e Jupyter. 3. ed. São Paulo: Novatec, 2023.

NUMPY DEVELOPERS. NumPy documentation: random sampling (numpy.random). Disponível em: <https://numpy.org/doc/stable/reference/random/index.html>. Acesso em: 10 set. 2026.

SCIPY COMMUNITY. SciPy documentation: statistical functions (scipy.stats). Disponível em: <https://docs.scipy.org/doc/scipy/reference/stats.html>. Acesso em: 10 set. 2026.

ANTHROPIC. Claude: modelo de linguagem de grande porte. Versão Opus 5. San Francisco: Anthropic, 2026. Disponível em: <https://claude.ai>. Acesso em: 10 set. 2026. Utilizado como apoio na estruturação da apresentação e na revisão do código.

Código-fonte completo no arquivo `codigo_cp4.py`, executado em Python 3.11 com NumPy, pandas, SciPy e Matplotlib.