

Probabilidade e Distribuição Normal aplicadas à Inteligência Artificial

Previsão de atrasos em entregas: estudo aplicado à Logística com dados simulados em Python

INTEGRANTES

Giovanni Henrique Pereira Hessel (RM 570574)

Suellen Pereira da Silva (RM 573862)

Arthur Zeferino (RM 570858)

Israel Carneiro de Toledo (RM 573854)

1 Introdução e Justificativa

Qual problema escolhemos e por que ele precisa de probabilidade

Uma transportadora promete entregar em até 60 minutos. Só que trânsito, chuva e distância mudam esse tempo, então ninguém tem certeza se vai dar. Quando a certeza não existe, a saída é calcular a chance de acontecer. É isso que os dois temas fazem, e é assim que um programa de computador consegue prever.

1 Contexto: Transportadora urbana com SLA de 60 minutos por entrega.

2 Problema: Quais fatores elevam o risco de atraso e qual a chance de estourar o prazo?

3 Solução: Um programa em Python que calcula a chance de atraso de cada entrega.

4 Dados: Mil entregas criadas pelo próprio código, sempre iguais por causa da semente fixa.

O QUE VAMOS RESPONDER

1. Qual a probabilidade de uma entrega atrasar?
2. Quanto a chuva aumenta esse risco?
3. O tempo de entrega segue uma Normal?
4. Dá para prever o atraso antes de ele acontecer?
5. Qual mudança na operação reduz mais o risco?

2 Probabilidade: conceitos e fórmulas

Tema 1: as três fórmulas que usamos no trabalho

Probabilidade

$$P(A) = \text{casos favoráveis} / \text{casos possíveis}$$

Quantas vezes o evento aconteceu, dividido pelo total.

Exemplo: Num dado comum, a chance de sair 6 é 1 em 6, ou seja, 16,7%.

Probabilidade condicional

$$P(A|B) = P(A \text{ e } B) / P(B)$$

A chance de algo acontecer quando já sabemos que outra coisa aconteceu.

Exemplo: Se alguém já disse que saiu número par, a chance de ser 6 sobe para 1 em 3.

Teorema de Bayes

$$P(B|A) = P(A|B) \times P(B) / P(A)$$

Vira a pergunta do avesso: a partir do resultado, descobre a causa provável.

Exemplo: O médico vê a febre e calcula qual doença é a causa mais provável.

REGRAS BÁSICAS

Toda chance fica entre 0 e 1 (0% e 100%)

A soma de todas as possibilidades dá 1

Se A e B não acontecem juntos, somam-se as chances

Onde isso é usado

- Aplicativo que avisa se vai chover hoje
- Filtro que separa e-mail de spam
- Banco que avalia risco de um empréstimo
- Netflix e YouTube sugerindo o próximo vídeo

3 A base de dados: números pseudoaleatórios

Mil entregas criadas pelo próprio programa

O computador não sorteia de verdade. Ele segue uma conta que parte de um número inicial, a semente, e devolve valores que parecem sorteados. Como a semente está fixa em 42, rodar o código hoje ou amanhã dá exatamente o mesmo resultado.

```
rng = np.random.default_rng(42) # semente fixa

distancia = np.clip(rng.normal(12, 4, n), 1, None)
chuva      = rng.binomial(1, 0.30, n) # Bernoulli
pico       = rng.binomial(1, 0.40, n) # Bernoulli

tempo = (6 + 3.0*distancia + 12*chuva + 9*pico
         + rng.normal(0, 7, n)) # ruído Normal

df['atraso'] = (df['tempo_min'] > 60).astype(int)
```

Parece sorteio, mas é repetível

É como um baralho embaralhado sempre da mesma forma: o resultado parece sorteado, mas qualquer pessoa consegue repetir o mesmo embaralhamento e conferir nossas contas.

1.000

entregas simuladas

42

semente (seed)

5

variáveis


Amostra da base gerada (df.head)

distância	chuva	pico	tempo	atraso
13,22 km	0	1	49,9	0
15,76 km	0	1	69,5	1
4,20 km	0	1	27,2	0
12,51 km	0	1	48,4	0

A última coluna é o que queremos prever: vale 1 quando o tempo passa de 60 minutos.

4 Probabilidade condicional na prática

Rodando o código: o risco muda muito de um cenário para outro



```
P(atraso | chuva) = df.loc[df['chuva']==1, 'atraso'].mean()
```

LEITURA DOS RESULTADOS

P(atraso) **22,5%**

P(atraso | sem chuva) **14,3%**

P(atraso | chuva) **41,0%**

P(atraso | pico) **36,1%**

P(atraso | chuva e pico) 64,7%

Risco relativo da chuva

2,87x

Com chuva, a chance de perder o prazo quase triplica.

5

Teorema de Bayes na prática

De “está chovendo, qual a chance de atrasar?” para “atrasou, o que provavelmente aconteceu?”

$$P(\text{chuva} \mid \text{atraso}) = \frac{P(\text{atraso} \mid \text{chuva}) \cdot P(\text{chuva})}{P(\text{atraso})} = \frac{0,410 \cdot 0,307}{0,225} = 0,560$$

O que já sabemos

$P(\text{atraso} \mid \text{chuva}) = 0,410$

Das entregas com chuva, 41% atrasaram.

Chance de chover

$P(\text{chuva}) = 0,307$

Choveu em 30,7% das entregas da base.

Chance de atrasar

$P(\text{atraso}) = 0,225$

22,5% de todas as entregas atrasaram.

Resposta

$P(\text{chuva} \mid \text{atraso}) = 0,560$


Das entregas que atrasaram, 56% foram em dia de chuva.

Conferindo no código: contamos na base quantas entregas atrasadas tiveram chuva e deu 0,560, exatamente o mesmo valor da fórmula.

6

Distribuição Normal do tempo de entrega

Tema 2: a curva em formato de sino



A altura das pessoas e as notas de uma prova se comportam assim: a maioria fica perto da média e poucos ficam nos extremos. Com o tempo de entrega acontece o mesmo.

$$f(x) = 1/(\sigma\sqrt{2\pi}) \cdot e^{-(x-\mu)^2/2\sigma^2}$$

48,9

média μ (min)

15,4

desvio σ (min)

Chance de passar dos 60 minutos

$$z = (60 - 48,94) / 15,42 = 0,717$$

$$P(T > 60) = 1 - \Phi(0,717) = 23,7\%$$

Empírico na base = 22,5%


A curva também mostra que prometer 75 minutos daria conta de 95% das entregas.

7

Por que essa curva aparece tanto?

Conferindo se os dados realmente seguem a curva Normal

Teorema Central do Limite: a media amostral tende a Normal



No primeiro gráfico os dados são bem tortos, nada parecido com um sino. Mas quando tiramos médias de grupos de 5 e depois de 50, o desenho vai virando o sino da Normal. Por isso essa curva aparece em quase tudo.

Regra empírica 68-95-99,7

Intervalo	Teórico	Observado
$\mu \pm 1\sigma$	68,27%	67,00%
$\mu \pm 2\sigma$	95,45%	95,90%
$\mu \pm 3\sigma$	99,73%	99,80%

Shapiro-Wilk

$W = 0,995$ | $p = 0,093$

O valor de p ficou acima de 0,05, então os dados combinam com a Normal.

ONDE A CURVA NORMAL É USADA

- Ajuste inicial de redes neurais
- Deixar variáveis na mesma escala
- O modelo que usamos no próximo slide
- Encontrar valores fora do normal
- Programas que geram imagens
- Margem de erro de pesquisas e testes

8 Classificador Naive Bayes Gaussiano

O modelo que junta os dois temas

O modelo aprende como é cada grupo, entregas no prazo e entregas atrasadas: distância média, quanto chove e quanto pega horário de pico. Diante de uma entrega nova, compara com os dois grupos, escolhe o mais parecido e diz em quantos por cento confia.

$$P(\text{grupo} \mid \text{dados}) = P(\text{grupo}) \times P(\text{dados} \mid \text{grupo})$$

- Treinamos com 70% das entregas e testamos nas outras 30%.
- O nome “naive”, ingênuo, vem de tratar as colunas como independentes.
- A curva Normal entra para medir o quanto a distância combina com cada grupo.
- A resposta vem em porcentagem, não só um sim ou não.



```
def densidade_normal(x, mu, sigma):  
    return (1/(sigma*np.sqrt(2*np.pi))) * \  
           np.exp(-((x-mu)**2)/(2*sigma**2))  
  
def prever(X):  
    posterioris = []  
    for classe in [0, 1]:  
        p = parametros[classe]  
        veros = densidade_normal(  
            X, p['media'], p['desvio']).prod(axis=1)  
        posterioris.append(p['priori'] * veros)  
    post = np.vstack(posterioris)  
    post = post / post.sum(axis=0) # normaliza  
    return post.argmax(axis=0), post[1]
```

É o mesmo raciocínio de olhar uma fruta e dizer se é laranja ou limão pelo tamanho e pela cor: comparamos com o que já vimos antes de cada uma.

9

Resultados e simulação de cenários

Testamos em 300 entregas que o modelo nunca tinha visto



87,3%

Acurácia

89,1%

Precisão

55,4%

Recall

0,683

F1-score

PREVISÃO PARA NOVAS ENTREGAS

5 km, tempo bom 0,0%

12 km, com chuva 20,6%

18 km, horário de pico 69,9%

20 km, chuva e pico 97,7%


Uso na operação

Sabendo o risco de cada pedido antes de sair, a empresa pode mandar outro veículo, mudar a rota ou avisar o cliente antes do prazo estourar.

Quando o modelo avisa que vai atrasar, ele quase sempre acerta. O ponto fraco é deixar escapar algumas entregas que atrasaram por pouco.

10 Simulação de Monte Carlo

Testando mudanças na operação antes de aplicá-las



```
amostras = rng.normal(mu, sigma, 20000)
risco = (amostras > 60).mean()
```

REDUÇÃO DO RISCO

23,7% → 6,8%

Fazendo as duas mudanças juntas, o risco cai 17 pontos. Em cada 100 mil entregas, são cerca de 17 mil atrasos a menos.

Leitura dos cenários

- Ganhar tempo médio ajudou mais do que reduzir a variação.
- As duas mudanças juntas derrubam o risco a menos de um terço.
- Simular no computador evita testar a mudança direto na rua.

Conclusão

Análise dos resultados e benefícios da solução

1 A média escondia o risco real

Olhando só o total, 22,5% das entregas atrasam. Separando por cenário, o risco chega a 64,7%. A probabilidade mostrou onde estava o problema.

2 A curva Normal descreveu o tempo

Com média de 48,9 e desvio de 15,4 minutos, a curva calculou 23,7% de risco, bem perto dos 22,5% que realmente aconteceram.

3 Da fórmula ao programa que prevê

Usando só as fórmulas dos slides, o modelo acertou 87,3% das entregas de teste, que ele nunca tinha visto antes.

4 O ganho para a empresa

Na simulação, o risco cai de 23,7% para 6,8%. Isso significa menos multa por atraso, menos retrabalho e cliente mais satisfeito.

Como próximo passo, o mesmo modelo poderia ser testado com dados reais da empresa e comparado com outros métodos.

11 Bibliografia

Referências segundo as normas da ABNT (NBR 6023)

BUSSAB, Wilson de O.; MORETTIN, Pedro A. Estatística básica. 9. ed. São Paulo: Saraiva, 2017.

MONTGOMERY, Douglas C.; RUNGER, George C. Estatística aplicada e probabilidade para engenheiros. 7. ed. Rio de Janeiro: LTC, 2021.

FÁVERO, Luiz Paulo; BELFIORE, Patrícia. Manual de análise de dados: estatística e modelagem multivariada. Rio de Janeiro: LTC, 2017.

JAMES, Gareth et al. An introduction to statistical learning: with applications in Python. Cham: Springer, 2023.

GÉRON, Aurélien. Mãos à obra: aprendizado de máquina com Scikit-Learn, Keras & TensorFlow. 2. ed. Rio de Janeiro: Alta Books, 2021.

MCKINNEY, Wes. Python para análise de dados: tratamento de dados com Pandas, NumPy e Jupyter. 3. ed. São Paulo: Novatec, 2023.

NUMPY DEVELOPERS. NumPy documentation: random sampling (numpy.random). Disponível em: <https://numpy.org/doc/stable/reference/random/index.html>. Acesso em: 10 set. 2026.

SCIPY COMMUNITY. SciPy documentation: statistical functions (scipy.stats). Disponível em: <https://docs.scipy.org/doc/scipy/reference/stats.html>. Acesso em: 10 set. 2026.

ANTHROPIC. Claude: modelo de linguagem de grande porte. Versão Opus 5. San Francisco: Anthropic, 2026. Disponível em: <https://claude.ai>. Acesso em: 10 set. 2026. Utilizado como apoio na estruturação da apresentação e na revisão do código.

Código-fonte completo no arquivo `codigo_cp4.py`, executado em Python 3.11 com NumPy, pandas, SciPy e Matplotlib.