

# CHECKPOINT 4: PROBABILIDADE E DISTRIBUIÇÃO NORMAL NA INTELIGÊNCIA ARTIFICIAL

## Statistical Computing with R & Python Aplicação em Logística: previsão de atrasos em entregas

*Documentação do trabalho*

|                     |                                                                                                                                                              |
|---------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <b>Sala:</b>        | 1TIAPZ1                                                                                                                                                      |
| <b>Matéria:</b>     | Statistical Computing with R & Python                                                                                                                        |
| <b>Grupo:</b>       | Perceptron                                                                                                                                                   |
| <b>Integrantes:</b> | Giovanni Henrique Pereira Hessel (RM 570574)<br>Suellen Pereira da Silva (RM 573862)<br>Arthur Zeferino (RM 570858)<br>Israel Carneiro de Toledo (RM 573854) |

## 1. TEMA E APLICAÇÃO

Dos quatro temas propostos, o grupo escolheu dois: Probabilidade e a Inteligência Artificial, e Distribuição Normal e a Inteligência Artificial.

A aplicação é de Logística: prever o atraso de entregas de uma transportadora urbana com prazo prometido (SLA) de 60 minutos. Trânsito, chuva e distância mudam o tempo de percurso, então não existe certeza sobre o prazo. Quando não há certeza, resta calcular a chance, que é exatamente o que um modelo preditivo faz.

- Contexto: transportadora urbana, SLA de 60 minutos por entrega.
- Problema: identificar os fatores que elevam o risco e medir a chance de estourar o prazo.
- Solução: programa em Python que calcula a probabilidade de atraso de cada entrega.
- Dados: mil entregas geradas pelo próprio código, sem uso de dados reais.

## 2. BASE DE DADOS SIMULADA

O computador não sorteia de verdade. Ele parte de um valor inicial, a semente, e devolve números que se comportam como sorteados. Com a semente fixa em 42, qualquer execução produz o mesmo resultado, o que permite conferir todos os cálculos.

### 2.1 Variáveis geradas

| Variável     | Distribuição                          | Papel no estudo                           |
|--------------|---------------------------------------|-------------------------------------------|
| distancia_km | Normal(12; 4)                         | Distância percorrida na entrega           |
| chuva        | Bernoulli(0,30)                       | Indica se choveu no momento da entrega    |
| horario_pico | Bernoulli(0,40)                       | Indica se a entrega pegou horário de pico |
| tempo_min    | Soma dos efeitos + ruído Normal(0; 7) | Tempo total da entrega                    |
| atraso       | Regra: tempo > 60 min                 | Variável alvo, o que queremos prever      |

## 3. PROBABILIDADE APLICADA

Na média, 22,5% das entregas atrasam. A média sozinha esconde a operação real: separando por cenário, o risco vai de 8% a 64,7%.

| Cenário                  | Probabilidade de atraso |
|--------------------------|-------------------------|
| Sem chuva e fora do pico | 8,0%                    |
| Somente horário de pico  | 24,0%                   |
| Somente chuva            | 27,0%                   |
| Chuva e horário de pico  | 64,7%                   |
| Média geral da base      | 22,5%                   |

### 3.1 Teorema de Bayes

A pergunta comum é: está chovendo, qual a chance de atrasar? A resposta é 41,0%. Bayes inverte a pergunta: a entrega atrasou, qual a chance de ter chovido?

$P(\text{chuva} | \text{atraso}) = 0,410 \times 0,307 / 0,225 = 0,560$ . Contando diretamente na base, 56,0% das entregas atrasadas ocorreram sob chuva. O cálculo bate com a realidade observada.

## 4. DISTRIBUIÇÃO NORMAL

O tempo de entrega tem média de 48,9 minutos e desvio padrão de 15,4 minutos. A curva Normal ajustada acompanha o histograma dos dados quase perfeitamente, o que era esperado: o tempo é a soma de vários efeitos, e somas tendem à Normal.

- Escore z:  $(60 - 48,94) / 15,42 = 0,717$ .
- Chance de estourar o SLA pela curva: 23,7%. Observado na base: 22,5%.
- Teste de Shapiro-Wilk:  $W = 0,995$  e  $p = 0,093$ , acima de 0,05, portanto os dados são compatíveis com a Normal.
- Regra empírica confirmada: 67,0% a um desvio, 95,9% a dois e 99,8% a três.
- Percentil 95: prometer 75 minutos cumpriria o prazo em 95% das entregas.

## 5. MODELO PREDITIVO

O classificador Naive Bayes Gaussiano foi escrito do zero, sem biblioteca de machine learning. Bayes decide qual grupo é mais provável e a curva Normal mede o quanto os dados combinam com cada grupo. Treino com 70% da base, teste nos 30% restantes.

| Métrica  | Resultado |
|----------|-----------|
| Acurácia | 87,3%     |
| Precisão | 89,1%     |

| Métrica                 | Resultado         |
|-------------------------|-------------------|
| Recall                  | 55,4%             |
| F1-score                | 0,683             |
| Alarmes falsos no teste | 5 de 300 entregas |

## 5.1 Previsão para novas entregas

| Entrega                | Risco de atraso |
|------------------------|-----------------|
| 5 km, tempo bom        | 0,0%            |
| 12 km, com chuva       | 20,6%           |
| 18 km, horário de pico | 69,9%           |
| 20 km, chuva e pico    | 97,7%           |

## 6. SIMULAÇÃO DE MONTE CARLO

Foram 20 mil sorteios para cada cenário, com o objetivo de comparar decisões antes de aplicá-las na operação real.

| Cenário                                        | Risco de atraso |
|------------------------------------------------|-----------------|
| Operação atual                                 | 23,7%           |
| Roteirização otimizada, 6 min a menos na média | 13,6%           |
| Frota padronizada, 25% a menos no desvio       | 16,4%           |
| As duas ações combinadas                       | 6,8%            |

## 7. CONCLUSÃO

Como continuidade, o mesmo modelo poderia ser treinado com dados reais da operação e comparado com outras técnicas de classificação.

- A média escondia o risco: 22,5% no total, mas 64,7% em dias de chuva no horário de pico.
- A curva Normal descreveu bem o tempo de entrega e estimou o risco com erro de pouco mais de um ponto percentual.
- Com apenas as fórmulas dos dois temas, o modelo acertou 87,3% das previsões em dados nunca vistos.
- O ganho é mensurável: risco caindo de 23,7% para 6,8%, com reflexo em multas de SLA, retrabalho e satisfação do cliente.

## 8. ENTREGÁVEIS E ARQUIVOS

Conforme o item 04 do enunciado, apenas dois arquivos vão para o Microsoft Teams, postados por um único representante do grupo.

| Arquivo                    | Formato    | Finalidade                                    |
|----------------------------|------------|-----------------------------------------------|
| apresentacao_cp4.pdf       | PDF        | Parte escrita, 13 slides. Entrega obrigatória |
| codigo_cp4.py              | Python     | Código-fonte. Entrega obrigatória             |
| apresentacao_cp4.pptx      | PowerPoint | Versão editável, com notas do orador          |
| codigo_cp4_colab.ipynb     | Notebook   | Mesmo código para rodar no Google Colab       |
| roteiro_apresentacao.md    | Markdown   | Roteiro da fala de cada integrante            |
| base_entregas_simulada.csv | CSV        | Base gerada na execução                       |

### 8.1 Repositório

- Projeto: <https://github.com/susuelen153-design/Projeto-Python>
- Pasta do trabalho: checkpoint4, na branch claude/fiap-activity-presentation-32lh3o
- Execução do código: `pip install numpy pandas matplotlib scipy` e depois `python codigo_cp4.py`

## 9. DIVISÃO DA APRESENTAÇÃO ORAL

A parte II do enunciado vale 5,0 pontos e é individual. A presença e a fala de todos os integrantes são obrigatórias.

| Integrante                       | Slides  | Tempo |
|----------------------------------|---------|-------|
| Giovanni Henrique Pereira Hessel | 1 a 3   | 3 min |
| Suellen Pereira da Silva         | 4 a 6   | 3 min |
| Arthur Zeferino                  | 7 a 9   | 3 min |
| Israel Carneiro de Toledo        | 10 a 13 | 3 min |

## 10. BIBLIOGRAFIA

---

- BUSSAB, Wilson de O.; MORETTIN, Pedro A. Estatística básica. 9. ed. São Paulo: Saraiva, 2017.
- MONTGOMERY, Douglas C.; RUNGER, George C. Estatística aplicada e probabilidade para engenheiros. 7. ed. Rio de Janeiro: LTC, 2021.
- FÁVERO, Luiz Paulo; BELFIORE, Patrícia. Manual de análise de dados: estatística e modelagem multivariada. Rio de Janeiro: LTC, 2017.
- JAMES, Gareth et al. An introduction to statistical learning: with applications in Python. Cham: Springer, 2023.
- GÉRON, Aurélien. Mãos à obra: aprendizado de máquina com Scikit-Learn, Keras & TensorFlow. 2. ed. Rio de Janeiro: Alta Books, 2021.
- MCKINNEY, Wes. Python para análise de dados. 3. ed. São Paulo: Novatec, 2023.
- NUMPY DEVELOPERS. NumPy documentation: random sampling. Disponível em: <https://numpy.org/doc/stable/reference/random/index.html>. Acesso em: 10 set. 2026.
- SCIPY COMMUNITY. SciPy documentation: statistical functions. Disponível em: <https://docs.scipy.org/doc/scipy/reference/stats.html>. Acesso em: 10 set. 2026.
- ANTHROPIC. Claude: modelo de linguagem de grande porte. Versão Opus 5. San Francisco: Anthropic, 2026. Disponível em: <https://claude.ai>. Acesso em: 10 set. 2026.